

工程概率统计

Probability and Statistics for Engineering

第三章联合分布

Chapter 3 Joint Distributions

3.1 随机向量与联合分布

我们之前每次只考虑一个随机变量，然而，通常我们需要处理多个随机变量。例如：

- 一个随机选择的人的身高和体重。
- 新加坡在随机选择的一天的温度、湿度、风力、降水量。

由于同一对象的不同度量通常相互关联，因此应同时考虑它们。

这里我们将讨论如何同时研究两个随机变量 X 和 Y ，所有概念都可以推广到 n 个随机变量 X_1, X_2, \dots, X_n 。

随机向量 如果 $\omega \in \Omega \mapsto (X(\omega), Y(\omega))$ 是一个值在 \mathbb{R}^2 上的函数，则称 (X, Y) 是一个**随机向量**。
 (X, Y) 也可以称为二维随机变量。

联合累积分布函数

对于随机向量 (X, Y) ，无论是离散还是连续，其累积分布函数定义为

$$F(x, y) = P(X \leq x, Y \leq y), \quad \forall x, y \in \mathbb{R}.$$

$F(x, y)$ 也称为 X 和 Y 的**联合累积分布函数**。

你可以将 $\{X \leq x\}$ 视为事件 A ，将 $\{Y \leq y\}$ 视为事件 B ，那么

$$F(x, y) = P(A \cap B).$$

由此可知，对于 $\forall x, y \in \mathbb{R}$ ，我们有

$$\begin{aligned} 0 &\leq F(x, y) \leq 1 \\ F(+\infty, +\infty) &= 1, \quad F(-\infty, -\infty) = 0, \\ F(-\infty, y) &= 0, \quad F(x, -\infty) = 0. \end{aligned}$$

联合 CDF 可用于计算对于任何 $-\infty < x_1 < x_2 < \infty, -\infty < y_1 < y_2 < \infty$ 的 $P(x_1 < X \leq x_2, y_1 < Y \leq y_2)$ 。

$$P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) \geq 0.$$

有了联合 CDF，就可以直接定义边缘 CDF。

边缘 CDF 设 $F(x, y)$ 是 (X, Y) 的联合 CDF， $F_X(x)$ 是不考虑 Y 时 X 的 CDF， $F_Y(y)$ 是不考虑 X 时 Y 的 CDF，则对于 $\forall x, y \in \mathbb{R}$ ：

$$F_X(x) = F(x, \infty), \quad F_Y(y) = F(\infty, y).$$

$F_X(F_Y)$ 也称为 $X(Y)$ 的**边缘累积分布函数**。

注意：虽然联合 CDF 唯一地确定了边缘 CDF，但反之则不成立。

例 3.1

假设随机向量 (X, Y) 的联合 CDF 为 $(a, b, c$ 是常数)

$$F(x, y) = a \left(b + \arctan \frac{x}{2} \right) \left(c + \arctan \frac{y}{2} \right), \quad -\infty < x, y < \infty.$$

1. 确定 a, b, c 的值。
2. 计算 $P(-2 < X \leq 2, -2 < Y \leq 2)$ 。
3. 求 X 和 Y 的边缘 CDF。

解答

1. 根据联合 CDF 的基本性质，我们有：

$$F(+\infty, +\infty) = a \left(b + \frac{\pi}{2} \right) \left(c + \frac{\pi}{2} \right) = 1,$$

$$F(-\infty, +\infty) = a \left(b - \frac{\pi}{2} \right) \left(c + \frac{\pi}{2} \right) = 0,$$

$$F(+\infty, -\infty) = a \left(b + \frac{\pi}{2} \right) \left(c - \frac{\pi}{2} \right) = 0.$$

解得 $b = \frac{\pi}{2}, c = \frac{\pi}{2}, a = \frac{1}{\pi^2}$ 。

因此，联合 CDF 为

$$F(x, y) = \frac{1}{\pi^2} \left(\frac{\pi}{2} + \arctan \frac{x}{2} \right) \left(\frac{\pi}{2} + \arctan \frac{y}{2} \right).$$

2. 根据联合 CDF 的定义和性质，我们有：

$$\begin{aligned} P(-2 < X \leq 2, -2 < Y \leq 2) &= F(2, 2) - F(2, -2) - F(-2, 2) + F(-2, -2) \\ &= \frac{1}{\pi^2} \left[\left(\frac{\pi}{2} + \arctan(1) \right)^2 - 2 \left(\frac{\pi}{2} + \arctan(1) \right) \left(\frac{\pi}{2} + \arctan(-1) \right) + \left(\frac{\pi}{2} + \arctan(-1) \right)^2 \right] \\ &= \frac{1}{\pi^2} \left[\left(\frac{\pi}{2} + \arctan(1) \right) - \left(\frac{\pi}{2} + \arctan(-1) \right) \right]^2 = \frac{1}{\pi^2} \left[\frac{\pi}{4} - \left(-\frac{\pi}{4} \right) \right]^2 = \frac{1}{4}. \end{aligned}$$

3. 根据边缘分布的定义，我们有：

$$F_X(x) = F(x, +\infty) = \frac{1}{\pi^2} \left(\frac{\pi}{2} + \arctan \frac{x}{2} \right) \left(\frac{\pi}{2} + \frac{\pi}{2} \right) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{2},$$

$$F_Y(y) = F(+\infty, y) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{y}{2}.$$

离散随机向量的联合与边缘 PMF

对于随机向量 (X, Y) ，设 $S_X = \{x_1, x_2, \dots\}$ 和 $S_Y = \{y_1, y_2, \dots\}$ 分别是 X 和 Y 的支撑集。则 (X, Y) 的联合概率质量函数定义为

$$p(x_i, y_j) = P(X = x_i, Y = y_j) \triangleq p_{ij}, \quad i, j = 1, 2, \dots$$

联合 PMF 满足：

- 非负性： $p_{ij} \geq 0, i, j = 1, 2, \dots$
- 归一性： $\sum_i \sum_j p_{ij} = 1$

X 的**边缘概率质量函数**是不考虑 Y 时 X 的 PMF:

$$p_X(x_i) = P(X = x_i) = \sum_{j=1}^{\infty} p_{ij} \triangleq p_i, \quad i = 1, 2, \dots$$

类似地, Y 的边缘 PMF 为

$$p_Y(y_j) = P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij} \triangleq p_{\cdot j}, \quad j = 1, 2, \dots$$

联合 PMF 通常以表格形式显示:

$X \setminus Y$	y_1	y_2	\dots	y_j	\dots
x_1	p_{11}	p_{12}	\dots	p_{1j}	\dots
x_2	p_{21}	p_{22}	\dots	p_{2j}	\dots
\vdots	\vdots	\vdots	\ddots	\vdots	\vdots
x_i	p_{i1}	p_{i2}	\dots	p_{ij}	\dots
\vdots	\vdots	\vdots	\ddots	\vdots	\vdots

例 3.2

独立地投掷两个骰子。设 X 为较小的点数, Y 为较大的点数。如果两个骰子显示相同的点数, 例如 z 点, 则 $X = Y = z$ 。

1. 求 (X, Y) 的联合 PMF;
2. 求 X 的边缘 PMF。

解答

1. 由于两个骰子是独立投掷的, 不难得到 (X, Y) 的联合 PMF:

$X \setminus Y$	1	2	3	4	5	6
1	1/36	1/18	1/18	1/18	1/18	1/18
2	0	1/36	1/18	1/18	1/18	1/18
3	0	0	1/36	1/18	1/18	1/18
4	0	0	0	1/36	1/18	1/18
5	0	0	0	0	1/36	1/18
6	0	0	0	0	0	1/36

2. 有了 (X, Y) 的联合 PMF, 可以直接得到 X 的边缘 PMF 为:

取值	1	2	3	4	5	6
概率	11/36	9/36	7/36	5/36	3/36	1/36

连续随机向量的联合 PDF

如果存在一个非负函数 $f(x, y)$, 定义在所有 $x, y \in \mathbb{R}^2$ 上, 满足对于任何 $D \subset \mathbb{R}^2$,

$$P((X, Y) \in D) = \iint_{(x, y) \in D} f(x, y) dx dy,$$

则称 (X, Y) 是一个连续随机向量。 $f(x, y)$ 称为 (X, Y) 的联合概率密度函数。

特别地, (X, Y) 的联合 CDF 为

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv.$$

由此可得

$$f(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y).$$

联合 PDF 满足:

- 非负性: $f(x, y) \geq 0, \forall x, y \in \mathbb{R}$
- 归一性: $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$

类似于单随机变量的 PDF, 联合 PDF $f(x, y) \neq P(X = x, Y = y)$ 。相反, 它反映了概率在 (x, y) 附近的集中程度。

例 3.3

随机选择的机器的两个电子元件的寿命 (以年为单位) 用随机变量 X 和 Y 表示, 其联合 PDF 为

$$f(x, y) = \begin{cases} 2e^{-x-2y}, & 0 < x, y < \infty \\ 0, & \text{否则} \end{cases}$$

计算:

1. $P(X < 1, Y < 1)$
2. $P(X < Y)$

解答

1. 根据 (X, Y) 的联合 PDF 的定义, 我们有:

$$\begin{aligned} P(X < 1, Y < 1) &= \int_{-\infty}^1 \left(\int_{-\infty}^1 f(x, y) dx \right) dy = \int_0^1 \left(\int_0^1 2e^{-x-2y} dx \right) dy \\ &= \int_0^1 (2(1 - e^{-1})e^{-2y}) dy = (1 - e^{-1}) \int_0^1 2e^{-2y} dy \\ &= (1 - e^{-1})(1 - e^{-2}) \approx 0.5466. \end{aligned}$$

2. 再次根据 (X, Y) 的联合 PDF:

$$\begin{aligned} P(X < Y) &= \iint_{\{(x, y) | 0 < x < y < \infty\}} f(x, y) dx dy = \int_0^{\infty} \left(\int_0^y 2e^{-x-2y} dx \right) dy \\ &= \int_0^{\infty} 2e^{-2y}(1 - e^{-y}) dy = \int_0^{\infty} 2e^{-2y} dy - \int_0^{\infty} 2e^{-3y} dy \\ &= 1 - \frac{2}{3} = \frac{1}{3}. \end{aligned}$$

连续随机向量的边缘 PDF

(X, Y) 是一个具有联合 PDF $f(x, y)$ 的连续随机向量, 则 X 的**边缘概率密度函数**, 即不考虑 Y 时 X 的 PDF 为

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy.$$

类似地, Y 的边缘 PDF 为

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx.$$

注意: 联合 PDF 唯一地定义了边缘 PDF, 但反之则不成立。

例 3.4

假设随机向量 (X, Y) 的联合 PDF 为

$$f(x, y) = \begin{cases} c, & \text{若 } x^2 + y^2 \leq R^2 \\ 0, & \text{否则} \end{cases}$$

1. 确定常数 c
2. 求 X 的边缘 PDF

解答

1. 根据联合 PDF 的归一性:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1,$$

由此可得

$$1 = \iint_{x^2+y^2 \leq R^2} c dx dy \implies c \cdot (\pi R^2) = 1 \implies c = \frac{1}{\pi R^2}.$$

2. 有了 (X, Y) 的联合 PDF, 可以直接得到 X 的边缘 PDF 为:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\sqrt{R^2-x^2}}^{\sqrt{R^2-x^2}} \frac{1}{\pi R^2} dy = \frac{2\sqrt{R^2-x^2}}{\pi R^2}, \quad \text{若 } |x| \leq R$$

且 $f_X(x) = 0$, 否则。

条件 PMF/PDF

对于具有联合 PMF $p(x, y)$ 的离散随机向量 (X, Y) , 给定 $Y = y$ 时 X 的**条件概率质量函数**定义为

$$p_{X|Y}(x|y) \triangleq P(X = x|Y = y) = \frac{p(x, y)}{p_Y(y)},$$

对于所有满足 $p_Y(y) > 0$ 的 y 值。

对于具有联合 PDF $f(x, y)$ 的连续随机向量 (X, Y) , 给定 $Y = y$ 时 X 的**条件概率密度函数**定义为

$$f_{X|Y}(x|y) \triangleq \frac{f(x, y)}{f_Y(y)} \quad (-\infty < x < \infty),$$

对于所有满足 $f_Y(y) > 0$ 的 y 值。

条件 PDF 反映了离散情况下条件 PMF 的定义, 只是将联合/边缘 PMF 替换为联合/边缘 PDF。

条件 PMF/PDF 也满足非负性和归一性。

问题：对于连续情况， $P(Y = y) = 0$ ，因此 $P(X = x|Y = y)$ 或 $P(X \leq x|Y = y)$ 没有定义。那么如何理解给定 $Y = y$ 时 X 的条件 PDF？

以 $Y = y$ 为条件可以理解为以 $\{y \leq Y \leq y + \epsilon\}$ 为条件，其中 $\epsilon \rightarrow 0$ 。

考虑条件 CDF：

$$\begin{aligned} P\{X \leq x | y < Y \leq y + \epsilon\} &= \frac{P\{X \leq x, y < Y \leq y + \epsilon\}}{P\{y < Y \leq y + \epsilon\}} \\ &= \frac{\int_{-\infty}^x \int_y^{y+\epsilon} f(u, v) dv du}{\int_y^{y+\epsilon} f_Y(v) dv} \\ &\rightarrow \int_{-\infty}^x \left(\frac{f(u, y)}{f_Y(y)} \right) du \quad (\epsilon \rightarrow 0). \end{aligned}$$

根据条件 PDF 的定义，我们有

$$f(x, y) = f_{X|Y}(x|y)f_Y(y).$$

对两边关于 y 积分， X 的边缘分布可以表示为

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\infty}^{\infty} f_{X|Y}(x|y)f_Y(y) dy$$

这就是连续情况下的全概率定律。

例 3.5

对于随机选择的交通事故中的人，设 X 为他/她的受伤程度， Y 为事故时他/她佩戴的安全装置类型。 X 和 Y 的联合 PMF 为

$X \backslash Y$	1 (无)	2 (仅安全带)	3 (安全带和安全带)	$p_X(x)$
1 (无)	0.065	0.075	0.060	0.20
2 (轻微)	0.165	0.160	0.125	0.45
3 (严重)	0.145	0.10	0.055	0.30
4 (死亡)	0.025	0.015	0.010	0.05
$p_Y(y)$	0.40	0.35	0.25	1.00

1. 对于随机选择的未使用任何安全装置的人，其受伤程度的 PMF 是什么？
2. 对于随机选择的佩戴了安全带和安全带的人，其受伤程度的 PMF 是什么？

解答

1. 根据条件 PMF 的定义，给定 $Y = 1$ 时 X 的条件分布为

取值	1 (无)	2 (轻微)	3 (严重)	4 (死亡)
概率	$\frac{0.065}{0.4} = 0.1625$	$\frac{0.165}{0.4} = 0.4125$	$\frac{0.145}{0.4} = 0.3625$	$\frac{0.025}{0.4} = 0.0625$

2. 类似地，给定 $Y = 3$ 时 X 的条件分布为

佩戴安全带和安全带时，严重受伤或死亡的概率比未使用任何安全装置的情况低 16.5%。

取值	1 (无)	2 (轻微)	3 (严重)	4 (死亡)
概率	$\frac{0.06}{0.25} = 0.24$	$\frac{0.125}{0.25} = 0.50$	$\frac{0.055}{0.25} = 0.22$	$\frac{0.01}{0.25} = 0.04$

例 3.4 (续)

确定给定 $Y = y$ (其中 $|y| \leq R$) 时 X 的条件 PDF。

解答 与例 3.4 类似, 我们得到 Y 的边缘 PDF:

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \begin{cases} \frac{2\sqrt{R^2 - y^2}}{\pi R^2}, & \text{若 } |y| \leq R, \\ 0, & \text{否则} \end{cases}$$

然后, 根据定义, 给定 $Y = y$ 时 X 的条件 PDF 为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \begin{cases} \frac{1}{2\sqrt{R^2 - y^2}}, & \text{若 } |x| \leq \sqrt{R^2 - y^2}, \\ 0, & \text{否则} \end{cases}$$

这表明给定 $Y = y$, X 服从均匀分布 $\text{Uniform}[-\sqrt{R^2 - y^2}, \sqrt{R^2 - y^2}]$ 。由于 $f_{X|Y}(x|y) \neq f_X(x)$, 我们说 X 不独立于 Y 。

3.2 两个随机变量之间的关系

在 3.1 节的末尾, 我们提到了随机变量之间独立性的概念。回顾随机事件之间的独立性, 随机变量之间的独立性可以类似定义: Y 的值不影响 X 的分布, 反之亦然。例如, 对于连续情况:

$$\begin{aligned} f_{X|Y}(x|y) = f_X(x) &\Rightarrow f(x, y) = f_{X|Y}(x|y)f_Y(y) = f_X(x)f_Y(y), \\ f_{Y|X}(y|x) = f_Y(y) &\Rightarrow f(x, y) = f_{Y|X}(y|x)f_X(x) = f_X(x)f_Y(y). \end{aligned}$$

由 $f(x, y) = f_X(x)f_Y(y)$, 我们有

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv = \int_{-\infty}^x f_X(u) du \int_{-\infty}^y f_Y(v) dv = F_X(x)F_Y(y).$$

随机变量的独立性

设 $F(x_1, x_2, \dots, x_n)$ 是 (X_1, X_2, \dots, X_n) 的联合 CDF, $F_{X_i}(x_i)$ 是 X_i 的边缘 CDF, 那么如果对于所有 $x_1, x_2, \dots, x_n \in \mathbb{R}$ 我们有

$$F(x_1, x_2, \dots, x_n) = F_{X_1}(x_1)F_{X_2}(x_2) \cdots F_{X_n}(x_n),$$

则我们说随机变量 X_1, X_2, \dots, X_n 是 (相互) 独立的。

对于离散随机变量 X_1, X_2, \dots, X_n , 如果它们是独立的, 则 PMF 满足

$$p(x_1, x_2, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n) = p_{X_1}(x_1)p_{X_2}(x_2) \cdots p_{X_n}(x_n).$$

对于连续随机变量 X_1, X_2, \dots, X_n , 如果它们是独立的, 则 PDF 满足

$$f(x_1, x_2, \dots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2) \cdots f_{X_n}(x_n).$$

问题: 三个或更多随机事件之间的独立性定义需要多个方程, 为什么三个或更多随机变量之间的独立性只需要一个方程?

例 3.6

标准正态随机变量 Z 的 PDF 是 $f(z) = ce^{-z^2/2}$, $-\infty < z < \infty$ 。我们已经知道 $c = 1/\sqrt{2\pi}$, 但是, 这个值是如何得到的? 令人惊讶的是, 确定 c 的最简单方法是定义两个独立的标准正态随机变量, 并利用它们的联合 PDF 必须积分为 1 这一事实。

解答 令随机变量 $X \sim N(0, 1)$, $Y \sim N(0, 1)$, 且 X 和 Y 独立。则 X 和 Y 的联合 PDF 为

$$f(x, y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} = \frac{1}{2\pi} e^{-\frac{(x^2+y^2)}{2}}$$

由于联合 PDF 必须积分为 1, 我们有

$$1 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2\pi} e^{-\frac{(x^2+y^2)}{2}} dx dy$$

为了计算这个二重积分, 我们转换到极坐标, 使用代换 $x = r \cos \theta$, $y = r \sin \theta$ 以及 $dx dy = r dr d\theta$:

$$\frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{(x^2+y^2)}{2}} dx dy = \frac{1}{2\pi} \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta = \frac{1}{2\pi} \int_0^{2\pi} 1 d\theta = 1$$

这验证了 $c = 1/\sqrt{2\pi}$ 。

例 3.7

假设在随机选择的工作日进入购物中心的人数服从参数为 λ 的泊松分布。如果每个进入购物中心的人是男性的概率为 0.2, 是女性的概率为 0.8。证明进入购物中心的男性和女性人数是独立的泊松随机变量, 参数分别为 0.2λ 和 0.8λ 。

解答 令随机变量 X_1 和 X_2 分别为进入购物中心的男性和女性人数。根据独立性的定义, 我们需要证明对于 $\forall i_1, i_2 = 0, 1, \dots$,

$$P(X_1 = i_1, X_2 = i_2) = P(X_1 = i_1)P(X_2 = i_2).$$

令 $Y = X_1 + X_2$ 为进入购物中心的总人数, 则 $Y \sim \text{Poisson}(\lambda)$, 即

$$P(Y = i_1 + i_2) = e^{-\lambda} \frac{\lambda^{i_1+i_2}}{(i_1 + i_2)!}$$

给定 $Y = i_1 + i_2$, 则 $X_1 \sim \text{Binomial}(i_1 + i_2, 0.2)$, 所以

$$P(X_1 = i_1 | Y = i_1 + i_2) = \binom{i_1 + i_2}{i_1} (0.2)^{i_1} (0.8)^{i_2} = \frac{(i_1 + i_2)!}{i_1! i_2!} (0.2)^{i_1} (0.8)^{i_2}$$

因此,

$$\begin{aligned} P(X_1 = i_1, X_2 = i_2) &= P(X_1 = i_1, X_2 = i_2 | Y = i_1 + i_2) P(Y = i_1 + i_2) \\ &= \frac{(i_1 + i_2)!}{i_1! i_2!} (0.2)^{i_1} (0.8)^{i_2} \times e^{-\lambda} \frac{\lambda^{i_1+i_2}}{(i_1 + i_2)!} \\ &= \left(e^{-0.2\lambda} \frac{(0.2\lambda)^{i_1}}{i_1!} \right) \left(e^{-0.8\lambda} \frac{(0.8\lambda)^{i_2}}{i_2!} \right) \end{aligned}$$

有了联合 PMF, 不难确定边缘 PMF, 即 $X_1 \sim \text{Poisson}(0.2\lambda)$ 和 $X_2 \sim \text{Poisson}(0.8\lambda)$, 并且 X_1 和 X_2 之间的独立性得证。

如果 X 和 Y 是独立的随机变量, 那么, 对于任何函数 g 和 h , 我们有

$$\begin{aligned} E[g(X)h(Y)] &= E[g(X)]E[h(Y)], \\ \text{Var}[g(X) \pm h(Y)] &= \text{Var}[g(X)] + \text{Var}[h(Y)]. \end{aligned}$$

证明： 不失一般性，展示连续情况。

假设 X 和 Y 具有联合密度 $f(x, y)$ ，则

$$\begin{aligned} E[g(X)h(Y)] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f(x, y)dxdy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f_X(x)f_Y(y)dxdy \\ &= \int_{-\infty}^{\infty} g(x)f_X(x)dx \int_{-\infty}^{\infty} h(y)f_Y(y)dy = E[g(X)]E[h(Y)]. \end{aligned}$$

令

$$E[g(X)] = a \quad \text{和} \quad E[h(Y)] = b,$$

则

$$\begin{aligned} \text{Var}[g(X) + h(Y)] &= E[(g(X) + h(Y) - a - b)^2] \\ &= E[(g(X) - a)^2] + E[(h(Y) - b)^2] + 2E[(g(X) - a)(h(Y) - b)] \\ &= \text{Var}[g(X)] + \text{Var}[h(Y)] + 2\text{Cov}(g(X), h(Y)). \end{aligned}$$

由于 X 和 Y 独立， $g(X)$ 和 $h(Y)$ 也独立（对于适当的函数），所以 $\text{Cov}(g(X), h(Y)) = 0$ ，因此

$$\text{Var}[g(X) + h(Y)] = \text{Var}[g(X)] + \text{Var}[h(Y)].$$

对于减法的情况类似（方差性质）。

特殊情况：如果 X 和 Y 独立，则 $E(XY) = E(X)E(Y)$ 且 $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ 。

如果 X 和 Y 不独立呢？考虑 $\text{Var}(X + Y)$ 和 $\text{Var}(X) + \text{Var}(Y)$ 之间的差异：

$$\text{Var}(X + Y) - \text{Var}(X) - \text{Var}(Y) = 2E[(X - E(X))(Y - E(Y))] = 2[E(XY) - E(X)E(Y)].$$

所以，如果 $E[(X - E(X))(Y - E(Y))] \neq 0$ ，则 X 和 Y 不可能独立。

因此， $E[(X - E(X))(Y - E(Y))]$ 可以用来衡量 X 和 Y 之间的关系。

协方差

X 和 Y 之间的协方差，记为 $\text{Cov}(X, Y)$ ，定义为

$$\text{Cov}(X, Y) \triangleq E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

如果 X 和 Y 独立，则 $\text{Cov}(X, Y) = 0$ 。然而，如果 $\text{Cov}(X, Y) = 0$ ， X 和 Y 可能不独立，我们只能说 X 和 Y 是不相关的。

例 3.4 (续)

我们已经知道 X 和 Y 不独立，但是，证明 $\text{Cov}(X, Y) = 0$ 。

证明 由于 X 和 Y 的边缘 PDF 都是偶函数，直接可知

$$E(X) = E(Y) = 0.$$

然后，我们计算 $E(XY)$ ：

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y)dxdy = \iint_{\{x^2+y^2 \leq R^2\}} \frac{xy}{\pi R^2} dxdy$$

$$= \frac{1}{\pi R^2} \int_{-R}^R \left(\int_{-\sqrt{R^2-y^2}}^{\sqrt{R^2-y^2}} x dx \right) y dy = 0.$$

(因为内层关于 x 的积分是奇函数在对称区间上的积分)

因此, $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0$ 。

注意, 当 X 和 Y 倾向于同方向变化时, $\text{Cov}(X, Y)$ 为正; 当它们倾向于反方向变化时, $\text{Cov}(X, Y)$ 为负。

协方差具有以下性质: (a, b, c 是常数)

- 协方差-方差关系: $\text{Cov}(X, X) = \text{Var}(X)$
- 对称性: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- 常数不协变: $\text{Cov}(X, c) = 0$
- 提取常数: $\text{Cov}(aX, bY) = ab \text{Cov}(X, Y)$
- 分配律: $\text{Cov}(X + X', Y) = \text{Cov}(X, Y) + \text{Cov}(X', Y)$
- 双线性性质:

$$\text{Cov} \left(\sum_{i=1}^n a_i X_i, \sum_{j=1}^m b_j Y_j \right) = \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(X_i, Y_j)$$

例 3.8

盖革计数器是一种用于检测和测量电离辐射的设备。每次检测到放射性粒子时, 它会发出咔哒声。假设在一个城市, 放射性粒子以 $\lambda = 0.8$ 粒子/秒的速率根据泊松过程到达盖革计数器。检测到第一个粒子的时间和检测到第二个粒子的时间分别记为 X 和 Y 。计算 X 和 Y 之间的协方差。

解答 令 $Z = Y - X$, 则 Z 表示第一个和第二个粒子到达之间的时间间隔。根据我们之前的知识, 我们知道 $X \sim \text{Exp}(\lambda)$, $Z \sim \text{Exp}(\lambda)$, 且 X 和 Z 独立。因此, 我们有

$$E(X) = E(Z) = \frac{1}{\lambda}, \quad \text{Var}(X) = \text{Var}(Z) = \frac{1}{\lambda^2}, \quad \text{且} \quad \text{Cov}(X, Z) = 0.$$

然后,

$$\text{Cov}(X, Y) = \text{Cov}(X, X + Z) = \text{Cov}(X, X) + \text{Cov}(X, Z) = \text{Var}(X) + 0 = \frac{1}{\lambda^2} = \frac{1}{0.8^2} = 1.5625.$$

$\text{Cov}(X, Y) > 0$ 与我们的直觉一致: 第一次到达等待的时间越长, 第二次到达等待的时间也越长, 因为第二次到达必须在第一次之后发生。

虽然协方差衡量了两个随机变量之间的关系, 但其值取决于我们测量随机变量所使用的单位/尺度。例如, 设 X (单位: 米) 和 Y (单位: 千克) 是一个随机选择的人的身高和体重, 且 $\bar{X} = 100X$ (即 \bar{X} 是以厘米为单位的身高), 则 $\text{Cov}(\bar{X}, Y) = 100\text{Cov}(X, Y)$ 。因此, 较大的协方差不一定意味着较强的关系。

为了使度量具有可比性, 我们需要消除单位/尺度的影响。

相关系数

X 和 Y 之间的相关系数, 记为 $\text{Cor}(X, Y)$ 或 ρ_{XY} , 定义为

$$\rho_{XY} = \text{Cor}(X, Y) \triangleq E \left[\frac{(X - E(X))}{\text{SD}(X)} \cdot \frac{(Y - E(Y))}{\text{SD}(Y)} \right] = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$

ρ_{XY} 是协方差的归一化版本, 它是一个无量纲的数值。

问题: ρ_{XY} 衡量的是哪种关系?

例 3.9

如果 X 和 Y 的联合 PDF 是 ($0 < c \leq 1$), 计算 ρ_{XY}

$$f(x, y) = \frac{1}{2\pi c} \exp \left\{ -\frac{x^2 - 2\sqrt{1-c^2}xy + y^2}{2c^2} \right\}, \quad -\infty < x, y < \infty.$$

解答 考虑 X 的边缘 PDF:

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x, y) dy \\ &= \frac{1}{2\pi c} \int_{-\infty}^{\infty} \exp \left\{ -\frac{(y - \sqrt{1-c^2}x)^2}{2c^2} - \frac{c^2x^2}{2c^2} \right\} dy \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \end{aligned}$$

所以 $X \sim N(0, 1)$, 类似地, 我们得到 $Y \sim N(0, 1)$ 。由此可知 $E(X) = E(Y) = 0$, $\text{Var}(X) = \text{Var}(Y) = 1$ 。

$$\begin{aligned} \text{Cov}(X, Y) &= E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y) dx dy \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (cuv + \sqrt{1-c^2}v^2) e^{-(u^2+v^2)/2} du dv \\ &= \frac{c}{2\pi} \int_{-\infty}^{\infty} u e^{-u^2/2} du \int_{-\infty}^{\infty} v e^{-v^2/2} dv + \frac{\sqrt{1-c^2}}{2\pi} \int_{-\infty}^{\infty} e^{-u^2/2} du \int_{-\infty}^{\infty} v^2 e^{-v^2/2} dv \\ &= 0 + \frac{\sqrt{1-c^2}}{2\pi} \cdot \sqrt{2\pi} \cdot \sqrt{2\pi} = \sqrt{1-c^2}. \end{aligned}$$

(因为第一个积分是奇函数, 第二个积分中 $\int_{-\infty}^{\infty} e^{-u^2/2} du = \sqrt{2\pi}$, $\int_{-\infty}^{\infty} v^2 e^{-v^2/2} dv = \sqrt{2\pi}$)

因此, $\rho_{XY} = \text{Cov}(X, Y) / \sqrt{\text{Var}(X)\text{Var}(Y)} = \sqrt{1-c^2}$ 。

这是一个例子, 说明边缘 PDF 不能唯一地确定联合 PDF。

ρ_{XY} 实际上衡量的是 X 和 Y 之间线性关系的方向和强度。

证明: 考虑使用 X 的线性函数来近似 Y , 即 $\hat{Y} = a + bX$ 。

那么, 近似的均方误差为

$$\begin{aligned} \text{MSE} &= E \left[(Y - \hat{Y})^2 \right] = E[(Y - a - bX)^2] \\ &= E(Y^2) + b^2 E(X^2) + a^2 - 2bE(XY) + 2abE(X) - 2aE(Y). \end{aligned}$$

接下来，我们希望关于 a 和 b 最小化 MSE。

$$\begin{aligned}\frac{\partial MSE}{\partial a} &= 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial MSE}{\partial b} &= 2bE(X^2) - 2E(XY) + 2aE(X) = 0\end{aligned}$$

解得

$$\begin{aligned}b_0 &= \frac{E(XY) - E(X)E(Y)}{E(X^2) - [E(X)]^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \\ a_0 &= E(Y) - b_0E(X) = E(Y) - \frac{\text{Cov}(X, Y)}{\text{Var}(X)}E(X)\end{aligned}$$

因此，

$$\begin{aligned}\min_{a,b} MSE &= E[(Y - a_0 - b_0X)^2] = E[(Y - E(Y) - b_0(X - E(X)))^2] \\ &= \text{Var}(Y) + b_0^2\text{Var}(X) - 2b_0\text{Cov}(X, Y) \\ &= \text{Var}(Y) + \frac{[\text{Cov}(X, Y)]^2}{\text{Var}(X)} - 2\frac{[\text{Cov}(X, Y)]^2}{\text{Var}(X)} \\ &= \text{Var}(Y) - \frac{[\text{Cov}(X, Y)]^2}{\text{Var}(X)} = \text{Var}(Y) \left[1 - \frac{[\text{Cov}(X, Y)]^2}{\text{Var}(X)\text{Var}(Y)} \right] = \text{Var}(Y)(1 - \rho_{XY}^2).\end{aligned}$$